

# 第九章 优化基础

## 第 31 讲 凸优化

黄定江

DaSE @ ECNU

djhuang@dase.ecnu.edu.cn

## 1 31.1 凸优化概念和性质

## 2 31.2 各种优化问题

## 1 31.1 凸优化概念和性质

## 2 31.2 各种优化问题

## 凸优化问题的标准形式

$$\begin{array}{ll}\text{minimize} & f_0(x) \\ \text{subject to} & f_i(x) \leq 0, i = 1, \dots, m \\ & h_i(x) = 0, i = 1, \dots, p\end{array}$$

- $x \in R^n$  是优化变量
- $f_0 : R^n \rightarrow R$  是目标函数或者损失函数
- $f_i : R^n \rightarrow R, \quad i = 1, \dots, m$  是不等式约束函数
- $h_i : R^n \rightarrow R$  是等式约束函数

## 凸优化问题的标准形式

**最优值：**

$$p^* = \inf\{f_0(x) | f_i(x) \leq 0, i = 1, \dots, m, h_i(x) = 0, i = 1, \dots, p\}$$

- $p^* = \pm\infty$ , 如果问题不可行 (没有  $x$  满足约束)
- $p^* = -\infty$ , 问题无下界

## 最优点与局部最优点

目标函数和约束函数所有有定义点的集合：

$$\mathcal{D} = \bigcap_{i=0}^m \text{dom } f_i \cap \bigcap_{i=0}^p \text{dom } h_i$$

如果  $x \in \mathcal{D}$  且满足约束  $f_i(x) \leq 0, i = 1, \dots, m, h_i(x) = 0, i = 1, \dots, p$ , 则  $x$  是可行的, 所有可行点的集合称为可行集。

## 最优点与局部最优点

可行的  $x$  是最优的如果  $f_0(x) = p^*$ ;  $X_{opt}$  是最优点的集合

可行解  $x$  为局部最优, 如果存在  $R > 0$  使得

$$\begin{array}{ll} \text{minimize} & f_0(x) \\ \text{subject to} & f_i(x) \leq 0, i = 1, \dots, m \quad h_i(x) = 0, i = 1, \dots, p \\ & \|z - x\|^2 \leq R \end{array}$$

## 最优点与局部最优点

### 例子

- $f_0(x) = \frac{1}{x}, \mathbf{dom} f_0 = R^{++} : p^* = 0$ , 无最优点
- $f_0(x) = -\log x, \mathbf{dom} f_0 = R^{++} : p^* = -\infty$
- $f_0(x) = x \log x, \mathbf{dom} f_0 = R^{++} : p^* = -\frac{1}{e}, x = \frac{1}{e}$  是最优点
- $f_0(x) = x^3 - 3x, p^* = -\infty, x = 1$  是局部最优



## 凸优化问题

## 标准形式的凸优化问题

$$\begin{aligned}
& \text{minimize} && f_0(x) \\
& \text{subject to} && f_i(x) \leq 0, \quad i = 1, \dots, m \\
& && a_i^T x = b_i, \quad i = 1, \dots, p
\end{aligned}$$

- $f_0, \dots, f_m$  为凸函数；等式约束是仿射的。

经常写作：

$$\begin{aligned}
& \text{minimize} && f_0(x) \\
& \text{subject to} && f_i(x) \leq 0, \quad i = 1, \dots, m \\
& && Ax = b
\end{aligned}$$

重要性质：凸优化问题的可行集是凸的。

## 例 1

$$\begin{aligned}
 & \text{minimize} && f_0(x) = x_1^2 + x_2^2 \\
 & \text{subject to} && f_1(x) = x_1/(1 + x_2^2) \leq 0 \\
 & && h_1(x) = (x_1 + x_2)^2 = 0
 \end{aligned}$$

- $f_0$  是凸的；可行集  $\{(x_1, x_2 | x_1 = -x_2 \leq 0)\}$  是凸的
- (根据定义) 不是凸优化问题：因为  $f_1$  不是凸的， $h_1$  不是仿射的。
- 等价于凸优化问题

$$\begin{aligned}
 & \text{minimize} && f_0(x) = x_1^2 + x_2^2 \\
 & \text{subject to} && f_1(x) = x_1 \leq 0 \\
 & && h_1(x) = x_1 + x_2 = 0
 \end{aligned}$$

## 局部最优和全局最优

凸优化问题中，局部最优点就是 (全局) 最优点。

**证明：** 设  $x$  是凸优化问题的局部最优解， $y$  是最优点使得  $f_0(y) < f_0(x)$

$x$  是局部最优解，存在  $R > 0$ . 有

$$z \text{ 可行}, \|z - x\|_2 \leq R \implies f_0(z) \geq f_0(x)$$

考虑  $z = (1 - \theta)x + \theta y$ ，其中  $\theta = R/2\|y - x\|_2$

- $\|y - x\|_2 > R$ ，因此  $0 < \theta < 1/2$
- $z$  是两个可行点的凸组合，因此也是可行的
- $\|z - x\|_2 = R/2 < R$  又

$$f_0(z) \leq (1 - \theta)f_0(x) + \theta f_0(y) < f_0(x)$$

与  $x$  是局部最优解矛盾。

## 可微函数 $f_0$ 的最优性准则

$x$  是最优解，当且仅当  $x$  可行，且

$$\nabla f_0(x)^T(y - x) \geq 0, \quad \text{对所有可行的 } y.$$

如果  $\nabla f_0(x) \neq 0$ ,  $-\nabla f_0(x)$  在  $x$  处定义了可行集  $X$  的一个支撑超平面。

- 无约束问题:  $x$  是最优点当且仅当

$$x \in \text{dom } f_0, \quad \nabla f_0(x) = 0$$

- 只含等式约束的问题:

$$\text{maximize } f_0(x) \quad \text{subject to } Ax = b$$

$x$  是最优点当且仅当存在  $v$ , 使得

$$x \in \text{dom } f_0, \quad Ax = b, \quad \nabla f_0(x) + A^T v = 0$$

- 非负象限中的极小化

$$\text{minimize } f_0(x) \quad \text{subject to } x \geq 0$$

$x$  是最优点当且仅当

$$x \in \text{dom } f_0, \quad x \geq 0, \quad \begin{cases} \nabla f_0(x)_i \geq 0 & x_i = 0 \\ \nabla f_0(x)_i = 0 & x_i > 0 \end{cases}$$

## 等价的凸问题

如果从一个问题的解，容易得到另一个问题的解，且反之亦然，称两问题（非正式定义）等价

- 消除等式约束

$$\begin{array}{ll}\text{minimize} & f_0(x) \\ \text{subject to} & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & Ax = b\end{array}$$

等价于

$$\begin{array}{ll}\text{minimize} & f_0(Fz + x_0) \\ \text{subject to} & f_i(Fz + x_0) \leq 0,\end{array}$$

其中  $F$  和  $x_0$  满足：

$$Ax = b \iff x = Fz + x_0$$

- 引入等式约束

$$\begin{array}{ll}\text{minimize} & f_0(A_0x + b_0) \\ \text{subject to} & f_i(A_ix + b_i) \leq 0, \quad i = 1, \dots, m\end{array}$$

等价于

$$\begin{array}{ll}\text{minimize} & f_0(y_0) \\ \text{subject to} & f_i(y_i) \leq 0, \quad i = 1, \dots, m \\ & y_i = A_ix + b_i, \quad i = 1, \dots, m\end{array}$$

- 引入松弛变量

$$\begin{array}{ll}\text{minimize} & f_0(x) \\ \text{subject to} & a_i^T x \leq b_i, \quad i = 1, \dots, m\end{array}$$

等价于

$$\begin{array}{ll}\text{minimize} & f_0(x) \\ \text{subject to} & a_i^T x + s_i = b_i, \quad i = 1, \dots, m \\ & s_i \geq 0, \quad i = 1, \dots, m\end{array}$$



1 31.1 凸优化概念和性质

2 31.2 各种优化问题

## 线性规划

$$\begin{array}{ll}\text{minimize} & c^T x + d \\ \text{subject to} & Gx \leq h \\ & Ax = b\end{array}$$

- 目标函数和约束函数都是仿射的凸优化问题
- 可行集是一个多面体

## 例子

**食谱问题：**选择  $n$  种食物的质量  $x_1, \dots, x_m$

- 每单位食物  $j$  的费用为  $c_j$ , 包含营养  $i$  的数量为  $a_{ij}$
- 健康饮食所需营养  $i$  的质量至少为  $b_i$

为了设计出一份最便宜的健康食谱,

$$\begin{array}{ll} \text{minimize} & c^T x \\ \text{subject to} & Ax \geq b, \quad x \geq 0 \end{array}$$

## 例子

## 分片线性极小化

$$\text{minimize} \quad \max_{i=1, \dots, m} (a_i^T x + b_i)$$

等价于一个线性规划问题：

$$\begin{array}{ll} \text{minimize} & t \\ \text{subject to} & a_i^T x + b_i \leq t, \quad i = 1, \dots, m \end{array}$$

## 例子

## 多面体的 Chebyshev 中心

多面体  $\mathcal{P} = \{x | a_i^T x \leq b_i, \quad i = 1, \dots, m\}$  的 Chebyshev 中心是最大的内切球球心  
 $\mathcal{B} = \{x_c + u | \|u\|_2 \leq r\}$

- 对于所有的  $x \in \mathcal{B}$ ,  $a_i^T x \leq b_i$  当且仅当  
 $\sup\{a_i^T(x_c + u) | \|u\|_2 \leq r\} = a_i^T x_c + r\|a_i\|_2 \leq b_i$
- 因此  $x_c, r$  可以通过解决一个 LP 问题被确定下来

$$\begin{array}{ll} \text{maximize} & r \\ \text{subject to} & a_i^T x_c + r\|a_i\|_2 \leq b_i, \quad i = 1, \dots, m \end{array}$$

## 线性分式规划

$$\begin{array}{ll}
 \text{minimize} & f_0(x) \\
 \text{subject to} & Gx \leq h \\
 & Ax = b
 \end{array}$$

## 线性分式规划

$$f_0(x) = \frac{c^T x + d}{e^T x + f}, \quad \text{dom } f_0 = \{x | e^T x + f \geq 0\}$$

可以转换为等价的线性规划

$$\begin{array}{ll}
 \text{minimize} & c^T y + dz \\
 \text{subject to} & Gy - hz \leq 0 \\
 & Ay - bz = 0 \\
 & e^T y + fz = 1 \\
 & z \geq 0
 \end{array}$$

## 二次优化问题

$$\begin{array}{ll}\text{minimize} & (1/2)x^T Px + q^T x + r \\ \text{subject to} & Gx \leq h \\ & Ax = b\end{array}$$

- $P \in S_+^n$  , 因此目标函数是凸二次型
- 在多面体上极小化一个凸二次函数

## 最小二乘问题

$$\|Ax - b\|_2^2$$

- 解析解  $x = A^\dagger b$ , 其中,  $A^\dagger$  是  $A$  的伪逆。
- 可以增加线性约束,  $l \leq x \leq u$



## 带有随机损失的线性规划

$$\begin{aligned}
 & \text{minimize} && \bar{c}^T x + \gamma x^T \Sigma x = \mathbf{E} c^T x + \gamma \mathbf{var}(c^T x) \\
 & \text{subject to} && Gx \leq h, \quad Ax = b
 \end{aligned}$$

- $c$  是随机向量，均值为  $\bar{c}$ ，协方差  $\Sigma$
- 因此， $c^T x$  是随机变量，均值  $\bar{c}^T x$  协方差  $x^T \Sigma x$
- $\gamma > 0$  为风险厌恶参数；权衡期望损失和方差 (风险)

## 二次约束二次规划 (QCQP)

$$\begin{aligned}
 & \text{minimize} && (1/2)x^T P_0 x + q_0^T x + r_0 \\
 & \text{subject to} && (1/2)x^T P_i x + q_i^T x + r_i \leq 0, \quad i = 1, \dots, m \\
 & && Ax = b
 \end{aligned}$$

- $P \in S_+^m$  , 目标和限制函数都是凸二次型
- 如果  $P \in S_{++}^m$  , 可行域是  $m$  个椭圆和一个仿射集合的交集

## 二阶锥规划

$$\begin{aligned}
 & \text{minimize} && f^T x \\
 & \text{subject to} && \|A_i x + b_i\|_2 \leq c_i^T x + d_i, \quad i = 1, \dots, m \\
 & && Fx = g
 \end{aligned}$$

$$(A_i \in R^{n_i \times n}, F \in R^{p \times n})$$

- 不等式称为二阶锥 (SOC) 约束:

$$(Ax + b, c^T x + d) \in R^{n_i+l} \text{ 的二阶锥中}$$

- $c_i = 0, i = 1, \dots, m$  时, SOCP 等同于 QCQO。
- $A_i = 0, i = 1, \dots, m$  时, SOCP 退化为 LP。

## 鲁棒线性规划

优化问题中的参数经常是不确定的, e.g. 在线性规划中

$$\begin{array}{ll}\text{minimize} & c^T x \\ \text{subject to} & a_i^T x \leq b_i, \quad i = 1, \dots, m\end{array}$$

其中的参数  $c, a_i, b_i$  含有一些不确定性或变化

## 鲁棒线性规划

两种通用方式处理不确定性 (简化起见, 只考虑  $a_i$ )

- 确定性方法: 所有的  $a_i \in \mathcal{E}_i$  必须满足约束

$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && a_i^T x \leq b_i, \quad \forall a_i \in \mathcal{E}_i, \quad i = 1, \dots, m \end{aligned}$$

- 随机性方法:  $a_i$  是随机变量; 以概率  $\eta$  满足约束

$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && \mathbf{prob}(a_i^T x \leq b_i) \geq \eta, \quad i = 1, \dots, m \end{aligned}$$

## SOCP 确定性方法

## 例 2

- 给定椭球  $\mathcal{E}_i$ :

$$a_i \in \mathcal{E}_i = \{\bar{a}_i + P_i u \mid \|u\|_2 \leq 1\} (\bar{a}_i \in R^n, \quad P_i \in R^{n \times n})$$

$\bar{a}_i$  是椭球中心，半轴由  $P_i$  的奇异值/奇异向量决定。

## SOCP 确定性方法

## 例 3

## • 鲁棒线性规划

$$\begin{aligned}
 & \text{minimize} && c^T x \\
 & \text{subject to} && a_i^T x \leq b_i, \quad \forall a_i \in \mathcal{E}_i, \quad i = 1, \dots, m
 \end{aligned}$$

等价于 SOCP

$$\begin{aligned}
 & \text{minimize} && c^T x \\
 & \text{subject to} && \bar{a}_i^T x + \|p_i^T x\|_2 \leq b_i, \quad i = 1, \dots, m
 \end{aligned}$$

由  $\sup_{\|u\|_2} (\bar{a}_i + P_i u)^T x = \bar{a}_i^T x + \|P_i^T x\|_2$  得到

## SOCP 随机性方法

## 例 4

- 假设  $a_i$  是服从高斯分布, 均值为  $\bar{a}_i$ , 协方差阵  $\Sigma_i$  ( $a_i \sim \mathcal{N}(\bar{a}_i, \Sigma_i)$ )
- $a_i^T x$  服从高斯分布, 均值为  $\bar{a}_i^T x$ , 协方差阵  $x^T \Sigma_i x$ ; 因此

$$\text{prob}(a_i^T x \leq b_i) = \phi\left(\frac{b_i - \bar{a}_i^T x}{\|\sum_i^{1/2} x\|_2}\right)$$

其中  $\phi(x) = (1/\sqrt{2\pi}) \int_{-\infty}^x e^{-t^2/2} dt$



## SOCP 随机性方法

## 例 5

## • 鲁棒线性规划

$$\begin{aligned}
 & \text{minimize} && c^T x \\
 & \text{subject to} && \mathbf{prob}(a_i^T x \leq b_i) \geq \eta, \quad i = 1, \dots, m,
 \end{aligned}$$

其中  $\eta \geq 1/2$ , 等价于 SOCP

$$\begin{aligned}
 & \text{minimize} && c^T x \\
 & \text{subject to} && \bar{a}_i^T x + \phi^{-1}(\eta) \|\Sigma_i^{1/2} x\|_2 \leq b_i, \quad i = 1, \dots, m,
 \end{aligned}$$