

第十一章 对偶理论

第 34 讲 分类模型

黄定江

DaSE @ ECNU

djhuang@dase.ecnu.edu.cn

1 34.1 分类

1 34.1 分类

34.1.1 线性判别

给定 R^n 中的两个点集 $\{x_1, \dots, x_N\}$ 和 $\{y_1, \dots, y_M\}$ 被某一超平面所分离

$$\begin{aligned} a^T x_i - b &> 0, \quad i = 1, \dots, N \\ a^T y_i - b &< 0, \quad i = 1, \dots, M \end{aligned} \quad (1)$$

等价于求解一组 a, b 的线性方程组

$$\begin{aligned} a^T x_i - b &\geq 1, \quad i = 1, \dots, N \\ a^T y_i - b &\leq -1, \quad i = 1, \dots, M \end{aligned} \quad (2)$$

34.1.1 线性判别




图 1: 点 x_1, \dots, x_N 由空心圆圈所示, y_1, \dots, y_M 由实心圆圈所示。两个集合由仿射函数 f 所分类, 其 0-水平集 (一条直线) 分离了它们

34.1.2 鲁棒线性判别

两个超平面之间的欧氏距离

$$H_1 = \{ z \mid a^T z - b = +1 \}$$

$$H_2 = \{ z \mid a^T z - b = -1 \}$$

为 $t = \text{dist}(H_1, H_2)$

通过最大化间隔来分离两个点集

$$\begin{aligned} & \text{minimize} && t \\ & \text{subject to} && a^T x_i - b \geq t, \quad i = 1, \dots, N \\ & && a^T y_i - b \leq -t, \quad i = 1, \dots, M \\ & && \|a\|_2 \leq 1 \end{aligned} \tag{3}$$

最优值 t^* 为正，当且仅当两个点集可以线性分离。不等式 $\|a\|_2 \leq 1$ 在最优解处总是紧的， $\|a\|_2 = 1$ 。图2给出一个简单的几何解释

34.1.2 鲁棒线性判别

如上图所示, 最优值 t^* (即带宽的一半) 是两个点集的凸包间距离的一半。(极小化- t 问题) 的 Lagrange 为

$$-t + \sum_{i=1}^N \mu_i(t + b - a^T x_i) + \sum_{i=1}^M \nu_i(t - b + a^T y_i) + \lambda(\|a\|_2 - 1)$$

在 b 和 t 上极小化得到条件 $a^T \mu = 1/2$, $1^T \nu = 1/2$ 。当它们成立时, 有

$$\begin{aligned} g(\mu, \nu, \lambda) &= \inf_a (a^T (\sum_{i=1}^M \nu_i y_i - \sum_{i=1}^N \mu_i x_i) + \lambda \|a\|_2 - \lambda) \\ &= \begin{cases} -\lambda & \|\sum_{i=1}^M \nu_i y_i - \sum_{i=1}^N \mu_i x_i\|_2 \leq \lambda \\ -\infty & \text{其他情况} \end{cases} \end{aligned}$$

34.1.2 鲁棒线性判别

对偶问题可以写成

$$\begin{aligned} \text{maximize} \quad & - \left\| \sum_{i=1}^M \nu_i y_i - \sum_{i=1}^N \mu_i x_i \right\|_2 \\ \text{subject to} \quad & \mu \geq 0, \quad 1^T \mu = 1/2 \\ & \nu \geq 1, \quad 1^T \nu = 1/2 \end{aligned} \tag{4}$$

可以将 $2 \sum_{i=1}^N \mu_i x_i$ 解释为 $\{x_1, \dots, x_N\}$ 的凸包上的一点，而 $2 \sum_{i=1}^M \nu_i y_i$ 是 $\{y_1, \dots, y_N\}$ 的凸包上的一点。对偶目标是极小化这两个点之间的（半距离），即寻找两个集合的凸包之间的（半）距离

34.1.3 间隔与支持向量

给定训练样本集 $D = (x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)$, $y_i \in \{-1, +1\}$, 分类学习最基本的想法就是基于训练集 D 在样本空间中找到一个划分超平面、将不同类别的样本分开, 但能将训练样本分开的划分超平面可能有很多, 我们应该去找到哪一个呢?




图 3: 存在多个划分超平面将两类训练样本分开

34.1.3 间隔与支持向量

超平面方程：

$$w^T x + b = 0 \quad (5)$$

$w = (w_1, w_2, \dots, w_d)$ 为法向量，决定了超平面的方向； b 为位移项，决定了超平面与原点之间的距离

样本空间中任一点 x 到超平面 (w, b) 的距离可写为

$$r = \frac{|w^T x + b|}{\|w\|} \quad (6)$$




图 4: 支持向量与间隔

34.1.3 间隔与支持向量

欲找到具有“最大间隔” (maximun margin) 的划分超平面，也就是要找到能满足式中约束的参数 w 和 b ，使得 γ 最大

$$\begin{aligned} \max_{w,b} \quad & \frac{2}{\|w\|} \\ \text{s.t.} \quad & y_i(w^T x_i + b) \geq 1, \quad i = 1, 2, \dots, m \end{aligned}$$

为了最大化间隔，仅需最大化 $\|w\|^{-1}$ ，这等价于最小化 $\|w\|^2$ 。

$$\begin{aligned} \min_{w,b} \quad & \frac{1}{2} \|w\|^2 \\ \text{s.t.} \quad & y_i(w^T x_i + b) \geq 1, \quad i = 1, 2, \dots, m \end{aligned}$$

这是支持向量机 (Support vector Machine, 简称 SVM) 的基本型，本身是一个凸二次规划问题，能直接用现成的优化计算包求解，但有更高效的办法

对偶问题

- 添加拉格朗日乘子 $\alpha \geq 0$, 则该问题的拉格朗日函数可写为

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 + \sum_{i=1}^m \alpha_i (1 - y_i (w^T x_i + b))$$

- 令 $L(w, b, \alpha)$ 对 w 和 b 的偏导为零可得

$$w = \sum_{i=1}^m \alpha_i y_i x_i, \quad 0 = \sum_{i=1}^m \alpha_i y_i$$

- 回代可得

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j x_i^T x_j \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i = 1, 2, \dots, m \end{aligned}$$

对偶问题

最终模型:

$$f(x) = w^T x + b = \sum_{i=1}^m \alpha_i y_i x_i^T x + b$$

KKT 条件

$$\begin{cases} \alpha_i \geq 0 \\ y_i f(x_i) - 1 \geq 0 \\ \alpha_i (y_i f(x_i) - 1) = 0 \end{cases}$$

总有 $\alpha_i = 0$ 或 $y_i(x_i) = 1$

解的稀疏性: 训练完成后, 大部分的训练样本都不需保留, 最终模型仅与支持向量有关, 支持向量机因此而得名