

数据科学与工程数学基础 作业4

📅 2021年6月2日 上午

📊 13k 字 🕒 111 分钟

一

构建模型使得预测值与真实值的误差最小常用向量2-范数度量，求解模型过程中需要计算梯度，求梯度：

- $f(A) = \frac{1}{2}||Ax + b - y||_2^2$ ，求 $\frac{\partial f}{\partial A}$
- $f(x) = \frac{1}{2}||Ax + b - y||_2^2$ ，求 $\frac{\partial f}{\partial x}$

，其中 $A \in \mathbb{R}^{m \times n}, x \in \mathbb{R}^n, b, y \in \mathbb{R}^m$

由

$$\begin{aligned} f(\mathbf{A}, x) &= \frac{1}{2}||\mathbf{Ax} + \mathbf{b} - \mathbf{y}||_2^2 \\ &= \frac{1}{2}(\mathbf{Ax} + \mathbf{b} - \mathbf{y})^T (\mathbf{Ax} + \mathbf{b} - \mathbf{y}) \end{aligned}$$

可知



$$\begin{aligned}
df &= d \left[Tr \left(\frac{1}{2} (\mathbf{Ax} + \mathbf{b} - \mathbf{y})^T (\mathbf{Ax} + \mathbf{b} - \mathbf{y}) \right) \right] \\
&= \frac{1}{2} Tr \left[d \left((\mathbf{Ax} + \mathbf{b} - \mathbf{y})^T (\mathbf{Ax} + \mathbf{b} - \mathbf{y}) \right) \right] \\
&= \frac{1}{2} Tr \left[d(\mathbf{Ax} + \mathbf{b} - \mathbf{y})^T \cdot (\mathbf{Ax} + \mathbf{b} - \mathbf{y}) + (\mathbf{Ax} + \mathbf{b} - \mathbf{y})^T \cdot d(\mathbf{Ax} + \mathbf{b} - \mathbf{y}) \right] \\
&= \frac{1}{2} Tr \left[\mathbf{x}^T \cdot d\mathbf{A}^T \cdot (\mathbf{Ax} + \mathbf{b} - \mathbf{y}) + (\mathbf{Ax} + \mathbf{b} - \mathbf{y})^T \cdot d\mathbf{A} \cdot \mathbf{x} \right] \\
&= \frac{1}{2} \left\{ Tr \left[\mathbf{x}^T \cdot d\mathbf{A}^T \cdot (\mathbf{Ax} + \mathbf{b} - \mathbf{y}) \right] + Tr \left[(\mathbf{Ax} + \mathbf{b} - \mathbf{y})^T \cdot d\mathbf{A} \cdot \mathbf{x} \right] \right\} \\
&= \frac{1}{2} \left\{ Tr \left[d\mathbf{A}^T \cdot (\mathbf{Ax} + \mathbf{b} - \mathbf{y}) \cdot \mathbf{x}^T \right] + Tr \left[\mathbf{x} \cdot (\mathbf{Ax} + \mathbf{b} - \mathbf{y})^T \cdot d\mathbf{A} \right] \right\} \\
&= \frac{1}{2} \left\{ Tr \left[\mathbf{x} \cdot (\mathbf{Ax} + \mathbf{b} - \mathbf{y})^T \cdot d\mathbf{A} \right] + Tr \left[\mathbf{x} \cdot (\mathbf{Ax} + \mathbf{b} - \mathbf{y})^T \cdot d\mathbf{A} \right] \right\} \\
&= \frac{1}{2} Tr \left[2 \cdot \mathbf{x} \cdot (\mathbf{Ax} + \mathbf{b} - \mathbf{y})^T \cdot d\mathbf{A} \right] \\
&= Tr \left[\mathbf{x} \cdot (\mathbf{Ax} + \mathbf{b} - \mathbf{y})^T \cdot d\mathbf{A} \right]
\end{aligned}$$

故

$$\frac{\partial f}{\partial \mathbf{A}} = \left(\mathbf{x} \cdot (\mathbf{Ax} + \mathbf{b} - \mathbf{y})^T \right)^T = (\mathbf{Ax} + \mathbf{b} - \mathbf{y}) \cdot \mathbf{x}^T$$

又

$$\begin{aligned}
df &= \frac{1}{2} Tr \left[d(\mathbf{Ax} + \mathbf{b} - \mathbf{y})^T \cdot (\mathbf{Ax} + \mathbf{b} - \mathbf{y}) + (\mathbf{Ax} + \mathbf{b} - \mathbf{y})^T \cdot d(\mathbf{Ax} + \mathbf{b} - \mathbf{y}) \right] \\
&= \frac{1}{2} Tr \left[d\mathbf{x}^T \cdot \mathbf{A}^T \cdot (\mathbf{Ax} + \mathbf{b} - \mathbf{y}) + (\mathbf{Ax} + \mathbf{b} - \mathbf{y})^T \cdot \mathbf{A} \cdot d\mathbf{x} \right] \\
&= \frac{1}{2} \left\{ Tr \left[d\mathbf{x}^T \cdot \mathbf{A}^T \cdot (\mathbf{Ax} + \mathbf{b} - \mathbf{y}) \right] + Tr \left[(\mathbf{Ax} + \mathbf{b} - \mathbf{y})^T \cdot \mathbf{A} \cdot d\mathbf{x} \right] \right\} \\
&= \frac{1}{2} \left\{ Tr \left[(\mathbf{Ax} + \mathbf{b} - \mathbf{y})^T \cdot \mathbf{A} \cdot d\mathbf{x} \right] + Tr \left[(\mathbf{Ax} + \mathbf{b} - \mathbf{y})^T \cdot \mathbf{A} \cdot d\mathbf{x} \right] \right\} \\
&= \frac{1}{2} Tr \left[2 \cdot (\mathbf{Ax} + \mathbf{b} - \mathbf{y})^T \cdot \mathbf{A} \cdot d\mathbf{x} \right] \\
&= Tr \left[(\mathbf{Ax} + \mathbf{b} - \mathbf{y})^T \cdot \mathbf{A} \cdot d\mathbf{x} \right]
\end{aligned}$$

故

$$\frac{\partial f}{\partial \mathbf{x}} = \left((\mathbf{Ax} + \mathbf{b} - \mathbf{y})^T \cdot \mathbf{A} \right)^T = \mathbf{A}^T \cdot (\mathbf{Ax} + \mathbf{b} - \mathbf{y})$$

二

利用迹微分法求解

$$\frac{\partial \backslash \textcolor{red}{tr}(W^{-1})}{\partial W}$$

，其中 $W \in \mathbb{R}^{m \times m}$

由

$$\begin{aligned}
d\,Tr(\mathbf{W}^{-1}) &= Tr \left[d \left(\mathbf{W}^{-1} \right) \right] \\
&= Tr \left[-\mathbf{W}^{-1} \cdot d\mathbf{W} \cdot \mathbf{W}^{-1} \right] \\
&= Tr \left[-\left(\mathbf{W}^{-1} \right)^2 \cdot d\mathbf{W} \right]
\end{aligned}$$

可知

$$\frac{\partial Tr(\mathbf{W}^{-1})}{\partial \mathbf{W}} = -\left(\mathbf{W}^{-2} \right)^T$$

三



二次型是数据分析中常用函数，求

$$\frac{\partial x^T A x}{\partial x}, \frac{\partial x^T A x}{\partial A}$$

，其中 $A \in \mathbb{R}^{m \times m}, x \in \mathbb{R}^m$

由

$$\begin{aligned} d(\mathbf{x}^T \mathbf{A} \mathbf{x}) &= d \operatorname{Tr}(\mathbf{x}^T \mathbf{A} \mathbf{x}) \\ &= \operatorname{Tr}[d(\mathbf{x}^T \mathbf{A} \mathbf{x})] \\ &= \operatorname{Tr}[d\mathbf{x}^T \cdot \mathbf{A} \mathbf{x} + \mathbf{x}^T \mathbf{A} \cdot d\mathbf{x}] \\ &= \operatorname{Tr}[\mathbf{x}^T \mathbf{A}^T d\mathbf{x}] + \operatorname{Tr}[\mathbf{x}^T \mathbf{A} d\mathbf{x}] \\ &= \operatorname{Tr}[\mathbf{x}^T (\mathbf{A}^T + \mathbf{A}) d\mathbf{x}] \end{aligned}$$

故

$$\frac{\partial \mathbf{x}^T \mathbf{A} \mathbf{x}}{\partial \mathbf{x}} = (\mathbf{x}^T (\mathbf{A}^T + \mathbf{A}))^T = (\mathbf{A} + \mathbf{A}^T) \mathbf{x}$$

又

$$\begin{aligned} d(\mathbf{x}^T \mathbf{A} \mathbf{x}) &= \operatorname{Tr}[d(\mathbf{x}^T \mathbf{A} \mathbf{x})] \\ &= \operatorname{Tr}[\mathbf{x}^T \cdot d\mathbf{A} \cdot \mathbf{x}] \\ &= \operatorname{Tr}[\mathbf{x} \mathbf{x}^T d\mathbf{A}] \end{aligned}$$

故

$$\frac{\partial \mathbf{x}^T \mathbf{A} \mathbf{x}}{\partial \mathbf{A}} = (\mathbf{x} \mathbf{x}^T)^T = \mathbf{x} \mathbf{x}^T$$

四

定义 $(\exp(z))_i = \exp(z_i), (\ln(z))_i = \ln(z_i)$ ，则

$$f(z) = \frac{\exp(z)}{\mathbf{1}^T \exp(z)}$$

成为Softmax函数，如果 $q = f(z), J = -p^T \ln(q)$ ，其中 $p, q, z \in \mathbb{R}^n$ ，并且 $\mathbf{1}^T p = 1$ ，则

- 证明： $\frac{\partial J}{\partial z} = q - p$
- 若 $z = Wx$ ，其中 $W \in \mathbb{R}^{n \times m}, x \in \mathbb{R}^m$ ， $\frac{\partial J}{\partial W} = (q - p)x^T$ 是否成立。

$\forall \mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^2, \lambda \in \mathbb{R}$

(1) 任取 $i, j \in \{1, 2, \dots, n\}$

易得

$$\frac{\partial J}{\partial q_j} = -\frac{p_j}{q_j}$$

当 $i \neq j$ 时，

$$\frac{\partial q_j}{\partial z_i} = -\frac{e^{z_i+z_j}}{\left(\sum_{k=1}^n e^{z_k}\right)^2} = -q_i \cdot q_j$$

当 $i = j$ 时，

$$\frac{\partial q_j}{\partial z_i} = \frac{e^{z_i} \cdot \left(\sum_{k=1}^n e^{z_k}\right) - e^{2z_i}}{\left(\sum_{k=1}^n e^{z_k}\right)^2} = q_i - q_i^2$$

故



$$\begin{aligned}\frac{\partial J}{\partial z_i} &= \sum_{j=1}^n \frac{\partial J}{\partial q_j} \cdot \frac{\partial q_j}{\partial z_i} \\ &= \sum_{j \neq i} \left(-\frac{p_j}{q_j}\right) (-q_i q_j) + \left(-\frac{p_i}{q_i}\right) (q_i - q_i^2) \\ &= q_i \cdot \sum_{j \neq i} p_j - p_i(1 - q_i)\end{aligned}$$

于是由 $1^T \boldsymbol{p} = \sum_{i=1}^n p_i = 1$ 可知

$$\frac{\partial J}{\partial z_i} = q_i(1 - p_i) - p_i(1 - q_i) = q_i - p_i$$

即

$$\frac{\partial J}{\partial \mathbf{z}} = \mathbf{q} - \mathbf{p}$$

(2) 由 $d\,Tr(\mathbf{W}\mathbf{x}) = Tr(d\mathbf{W} \cdot \mathbf{x}) = Tr(\mathbf{x} \cdot d\mathbf{W})$ 可知

$$\frac{\partial J}{\partial \mathbf{W}} = \mathbf{x}^T$$

故

$$\frac{\partial J}{\partial \mathbf{W}} = \frac{\partial J}{\partial \mathbf{z}} \cdot \frac{\partial \mathbf{z}}{\partial \mathbf{W}} = (\mathbf{q} - \mathbf{p})\mathbf{x}^T$$

成立

五

以下内容是利用极大似然估计求解多元正态分布模型的关键步骤：

$$L = -\frac{Nd}{2}\ln(2\pi) - \frac{N}{2}\ln|\Sigma| - \frac{1}{2}\sum_t (x_t - \mu)^T \Sigma^{-1} (x_t - \mu)$$

， L 是对数似然， N 为样本数， d 为样本维数， $\Sigma \in \mathbb{R}^{d \times d}$ 为协方差矩阵（对称矩阵）， $\mu \in \mathbb{R}^d$ 为期望向量。

- 求 $\frac{\partial L}{\partial \mu}$
- 当 $\mu = \frac{1}{N} \sum_t x_t$ 使，求 $\frac{\partial L}{\partial \Sigma}$ ，并求使 $\frac{\partial L}{\partial \Sigma} = 0$ 成立的 Σ 。

(1)

$$\begin{aligned}\frac{\partial L}{\partial \mu} &= -\frac{1}{2} \sum_{t=1}^N \frac{\partial}{\partial \mu} \big[(\mathbf{x}_t - \mu)^T \Sigma^{-1} (\mathbf{x}_t - \mu)\big] \\ &= -\frac{1}{2} \sum_{t=1}^N \frac{\partial \big[(\mathbf{x}_t - \mu)^T\big]}{\partial \mu} \cdot \frac{\partial \big[(\mathbf{x}_t - \mu)^T \Sigma^{-1} (\mathbf{x}_t - \mu)\big]}{\partial [\mathbf{x}_t - \mu]} \\ &= -\frac{1}{2} \sum_{t=1}^N \big[-2 \Sigma^{-1} (\mathbf{x}_t - \mu)\big] \\ &= \Sigma^{-1} \cdot \sum_{t=1}^N (\mathbf{x}_t - \mu)\end{aligned}$$

(2)

由



$$\begin{aligned} dL &= Tr \left[d \left(-\frac{Nd}{2} \ln(2\pi) - \frac{N}{2} \ln |\Sigma| - \frac{1}{2} \sum_{t=1}^N (\mathbf{x}_t - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x}_t - \boldsymbol{\mu}) \right) \right] \\ &= Tr \left[-\frac{N}{2} d(\ln |\Sigma|) - \frac{1}{2} \sum_{t=1}^N (\mathbf{x}_t - \boldsymbol{\mu})^T \cdot d(\Sigma^{-1}) \cdot (\mathbf{x}_t - \boldsymbol{\mu}) \right] \\ &= Tr \left[-\frac{N}{2|\Sigma|} \cdot |\Sigma| \Sigma^{-1} d\Sigma + \frac{1}{2} \sum_{t=1}^N (\mathbf{x}_t - \boldsymbol{\mu})(\mathbf{x}_t - \boldsymbol{\mu})^T \cdot \Sigma^{-1} d\Sigma \cdot \Sigma^{-1} \right] \\ &= Tr \left[\left(-\frac{N}{2} \cdot \Sigma^{-1} + \frac{1}{2} \sum_{t=1}^N \Sigma^{-1} (\mathbf{x}_t - \boldsymbol{\mu})(\mathbf{x}_t - \boldsymbol{\mu})^T \cdot \Sigma^{-1} \right) d\Sigma \right] \end{aligned}$$

及 Σ 为对称矩阵可知

$$\frac{\partial L}{\partial \Sigma} = \frac{1}{2} \sum_{t=1}^N \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} - \frac{N}{2} \Sigma^{-1}$$

故当 $\Sigma = \frac{1}{N} (\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T$ 时， $\frac{\partial L}{\partial \Sigma} = 0$

六

求

$$\frac{\partial |X_k|}{\partial X}$$

，其中 $X \in \mathbb{R}^{m \times m}$ 为可逆矩阵。

由 $\mathbf{X} \in \mathbb{R}^{m \times m}$ 可逆可知

$$\begin{aligned} \frac{\partial |\mathbf{X}^k|}{\partial \mathbf{X}} &= \frac{\partial |\mathbf{X}^k|}{\partial |\mathbf{X}|} \cdot \frac{\partial |\mathbf{X}|}{\partial \mathbf{X}} \\ &= k|\mathbf{X}|^{k-1} \cdot |\mathbf{X}| \cdot (\mathbf{X}^{-1})^T \\ &= k|\mathbf{X}|^k (\mathbf{X}^{-1})^T \end{aligned}$$

七

求

$$\frac{\partial \backslash \textcolor{red}{tr}(AXBX^TC)}{\partial X}$$

，其中 $A \in \mathbb{R}^{m \times n}, X \in \mathbb{R}^{n \times k}, B \in \mathbb{R}^{k \times k}, C \in \mathbb{R}^{n \times m}$

由

$$\begin{aligned} d\left(\mathbf{A}\mathbf{x}\mathbf{B}\mathbf{x}^T\mathbf{C}\right) &= Tr\left[d\left(\mathbf{A}\mathbf{x}\mathbf{B}\mathbf{x}^T\mathbf{C}\right)\right] \\ &= Tr\left[\mathbf{A}\cdot d\mathbf{x}\cdot\mathbf{B}\mathbf{x}^T\mathbf{C}+\mathbf{A}\mathbf{x}\mathbf{B}\cdot d\mathbf{x}^T\cdot\mathbf{C}\right] \\ &= Tr\left[\mathbf{B}\mathbf{x}^T\mathbf{C}\mathbf{A}d\mathbf{x}\right]+Tr\left[d\mathbf{x}^T\cdot\mathbf{C}\mathbf{A}\mathbf{x}\mathbf{B}\right] \\ &= Tr\left[\mathbf{B}\mathbf{x}^T\mathbf{C}\mathbf{A}d\mathbf{x}\right]+Tr\left[\mathbf{B}^T\mathbf{x}^T\mathbf{A}^T\mathbf{C}^T d\mathbf{x}\right] \\ &= Tr\left[\left(\mathbf{B}\mathbf{x}^T\mathbf{C}\mathbf{A}+\mathbf{B}^T\mathbf{x}^T\mathbf{A}^T\mathbf{C}^T\right)d\mathbf{x}\right] \end{aligned}$$

可知

$$\frac{\partial Tr\left(\mathbf{A}\mathbf{x}\mathbf{B}\mathbf{x}^T\mathbf{C}\right)}{\partial \mathbf{X}}=\left(\mathbf{B}\mathbf{x}^T\mathbf{C}\mathbf{A}+\mathbf{B}^T\mathbf{x}^T\mathbf{A}^T\mathbf{C}^T\right)^T=\mathbf{A}^T\mathbf{C}^T\mathbf{x}\mathbf{B}^T+\mathbf{C}\mathbf{A}\mathbf{x}\mathbf{B}$$

八



求激活函数

$$\sigma(x)=\frac{1}{1+e^{-x}}$$

的导数

$$\frac{d\sigma}{d\mathbf{x}}=\frac{d}{d\mathbf{x}}\left(\frac{1}{1+e^{-\mathbf{x}}}\right)=\frac{e^{-\mathbf{x}}}{\left(1+e^{-\mathbf{x}}\right)^2}=\sigma(\mathbf{x})\left(1-\sigma(\mathbf{x})\right)$$

九

求

$$\frac{\partial}{\partial x}\mathrm{exp}\left\{-\frac{1}{2||\sigma||_2^2}||x-\mu||_2^2\right\}$$

，其中 $x,\mu,\sigma\in\mathbb{R}^n$

由

$$\begin{aligned}d\left(e^{-\frac{1}{2||\sigma||^2}||\mathbf{x}-\boldsymbol{\mu}||_2^2}\right)&=Tr\left[d\left(e^{-\frac{2}{2||\sigma||^2}||\mathbf{x}-\boldsymbol{\mu}||_2^2}\right)\right] \\&=Tr\left[-\frac{1}{2||\boldsymbol{\sigma}||^2}e^{-\frac{1}{2||\sigma||^2}||\mathbf{x}-\boldsymbol{\mu}||_2^2}\cdot d\left(||\mathbf{x}-\boldsymbol{\mu}||_2^2\right)\right] \\&=Tr\left[-\frac{1}{2||\boldsymbol{\sigma}||^2}e^{-\frac{1}{2||\sigma||^2}||\mathbf{x}-\boldsymbol{\mu}||_2^2}\cdot d\left((\mathbf{x}-\boldsymbol{\mu})^T(\mathbf{x}-\boldsymbol{\mu})\right)\right] \\&=Tr\left[-\frac{(\mathbf{x}-\boldsymbol{\mu})^T}{||\boldsymbol{\sigma}||^2}e^{-\frac{1}{2||\sigma||^2}||\mathbf{x}-\boldsymbol{\mu}||_2^2}\cdot d\mathbf{x}\right]\end{aligned}$$

可知

$$\frac{\partial}{\partial \mathbf{x}}e^{-\frac{1}{2||\sigma||^2}||\mathbf{x}-\boldsymbol{\mu}||_2^2}=\left(-\frac{(\mathbf{x}-\boldsymbol{\mu})^T}{||\boldsymbol{\sigma}||^2}e^{-\frac{1}{2||\sigma||^2}||\mathbf{x}-\boldsymbol{\mu}||_2^2}\right)^T=-\frac{(\mathbf{x}-\boldsymbol{\mu})}{||\boldsymbol{\sigma}||^2}e^{-\frac{1}{2||\sigma||^2}||\mathbf{x}-\boldsymbol{\mu}||_2^2}$$

十

阅读以下代码，填写更新梯度部分的代码。（提交时，需要提交补全的代码，以及最后10次输出的截图）

实现代码：

 Copy



```
1 import numpy as np
2
3 N, D_in, H, D_out = 64, 1000, 100, 10
4 # 随机创建一些训练数据
5 x = np.random.randn(N, D_in)
6 y = np.random.randn(N, D_out)
7 w1 = np.random.randn(D_in, H)
8 w2 = np.random.randn(H, D_out)
9 learning_rate = 1e-6
10 for it in range(500):
11     # Forward pass
12     h = x.dot(w1) # N * H
13     h_relu = np.maximum(h, 0) # N * H
14     y_pred = h_relu.dot(w2) # N * D_out
15     # compute loss
16     loss = np.square(y_pred - y).sum()
17     print(it, loss)
18     # Backward pass
19     # compute the gradient
20     grad_y_pred = y_pred - y
21     grad_w2 = h_relu.T.dot(grad_y_pred)
22     grad_h_relu = grad_y_pred.dot(w2.T)
23     grad_h = grad_h_relu.copy()
24     grad_h[h < 0] = 0
25     grad_w1 = x.T.dot(grad_h)
26     w1 -= learning_rate * grad_w1
27     w2 -= learning_rate * grad_w2
```

输出结果（最后10次循环）：

🔗 [数据科学数学基础](#) 🔗 [Mathematics](#) [DataScience](#)

本博客所有文章除特别声明外，均采用 [CC BY-SA 4.0 协议](#)，转载请注明出处！

◀ [操作系统实验 内存管理](#)

[操作系统实验 I/O子系统](#) ▶

