

# 数据科学与工程数学基础

## 作业提交规范及第 5 次作业

教师：黄定江

助教：刘文辉、徐艺玮

2023 年 12 月 7 日

### 作业提交规范

1. 作业提交形式：建议使用 Word 或  $\text{\LaTeX}$  编写所得到的电子文档。若使用 Word 编写，将其另存为 PDF 形式，然后提交 PDF 文档。若使用  $\text{\LaTeX}$  编写，将其编译成 PDF 形式，然后提交 Tex 和 PDF 两个文档。若使用手写拍照的方式，请务必规整好各题解答的图片，并整合在一个 PDF 文档中，只发图片格式的作业概不批改！
2. 作业命名规范：提交的电子文档必须命名为：“学号\_姓名”。命名示例：52200000000\_刘某某。
3. 作业提交途径：点击打开每次作业的传送门地址：**第 5 次作业提交传送门**，无需注册和登录，按要求输入个人学号和姓名，然后上传作业文档即可。**注意：传送门将会在截至时间点到达后自动关闭。**
4. 作业更改说明：如果需要修改已经提交的作业，只要在截至日期前，再次上传更改后的作业（切记保持同名），即可覆盖已有作业。
5. 作业评分说明：正常提交作业的按照实际评分记录；逾期补交作业的根据逾期情况在实际评分基础上酌情扣分；**未交作业的当次作业记为 0 分**；若发现存在抄袭的作业时，相似的两份作业均会被记为 0 分。

### 第 5 次作业



提交截至时间：**2023/11/21 下周二 12:00（中午）**

## 理论部分

**习题 1.** 利用等式

$$\|A(x + \alpha w) - b\|_2^2 = \|Ax - b\|_2^2 + 2\alpha w^T A^T (Ax - b) + \alpha^2 \|Aw\|_2^2$$

证明: 如果  $x \in X_{LS}$ , 那么  $A^T Ax = A^T b$

**解.** 设  $f(\alpha) = \|A(x + \alpha w) - b\|_2^2$ , 由于  $x \in X_{LS}$ , 说明当  $\alpha = 0$  时, 函数取极小点. 由于  $f$  是关于  $\alpha$  的二次函数, 故在  $\alpha = -\frac{2w^T A^T (Ax - b)}{2\alpha^2 \|Aw\|_2^2}$  取得极值点. 代入  $\alpha = 0$ , 有

$$w^T A^T (Ax - b) = 0$$

又由于  $w$  的任意性, 有

$$A^T Ax = A^T b$$

**习题 2.**

$$A := \begin{pmatrix} 5 & -1 & 1 \\ -1 & 2 & 0 \\ 1 & 0 & 3 \end{pmatrix}$$

记  $\Lambda(A) = \{\lambda_1, \lambda_2, \lambda_3\} \subseteq \mathbb{C}$  with  $|\lambda_1| \geq |\lambda_2| \geq |\lambda_3|$ .

(i) 使用 *Gerschgorin* 圆盘定理, 证明  $\frac{|\lambda_1|}{|\lambda_3|} \leq 7$ . (注: 由于  $A$  为对称矩阵,  $\frac{|\lambda_1|}{|\lambda_3|}$  为  $A$  的条件数)

(ii) (编程题, 提交代码) 使用幂法与反幂法计算  $\frac{|\lambda_1|}{|\lambda_3|}$

**解.** (i) 令  $a \in \mathbb{C}$ ,  $r \in \mathbb{R}$ ,  $r > 0$ , 记  $D(a, r) := \{z \in \mathbb{C} : |z - a| \leq r\} \subseteq \mathbb{C}$ . 对  $A$  和  $A^T$  使用 *Gerschgorin* 圆盘定理, 有  $\Lambda(A) = \Lambda(A^T) \subseteq \tilde{G}_1 \cup \tilde{G}_2 \cup \tilde{G}_3$ , 其中

$$\tilde{G}_1 := D(5, 2), \tilde{G}_2 := D(2, 1), \tilde{G}_3 := D(3, 1)$$

可得  $|\lambda_1| \leq 7$ ,  $|\lambda_3| \geq 1$ . 故  $\frac{|\lambda_1|}{|\lambda_3|} \leq 7$ .

(ii)  $\frac{|\lambda_1|}{|\lambda_3|} \approx 3.4823$

**习题 3.** 构建模型使得预测值与真实值的误差最小常用向量 2-范数度量, 求解模型过程中需要计算梯度, 求梯度:

- $f(A) = \frac{1}{2} \|Ax + b - y\|_2^2$ , 求  $\frac{\partial f}{\partial A}$
- $f(x) = \frac{1}{2} \|Ax + b - y\|_2^2$ , 求  $\frac{\partial f}{\partial x}$

其中  $A \in R^{m \times n}$ ,  $x \in R^n$ ,  $b, y \in R^m$

**解.**

$$\begin{aligned} \frac{\partial}{\partial A} f &= \frac{\partial}{\partial A} \frac{1}{2} (x^T A^T Ax + 2(b - y)^T Ax + (b - y)^T (b - y)) \\ &= \frac{\partial}{\partial A} \frac{1}{2} (x^T A^T Ax + 2(b - y)^T Ax) \\ &= Axx^T + (b - y)x^T \end{aligned}$$

$$\frac{\partial}{\partial x} f = A^T Ax + A^T (b - y)$$

**习题 4.** 二次型是数据分析中常用函数, 求  $\frac{\partial x^T A x}{\partial x}$ ,  $\frac{\partial x^T A x}{\partial A}$ , 其中  $A \in R^{m \times m}$ ,  $x \in R^m$

**解.**  $\frac{\partial x^T A x}{\partial x} = (A + A^T)x$   
 $\frac{\partial x^T A x}{\partial A}_{ij} = x_i x_j, \frac{\partial x^T A x}{\partial A} = x x^T$

**习题 5.** 利用迹微分法求解  $\frac{\partial \text{Tr}(W^{-1})}{\partial W}$ , 其中  $W \in R^{m \times m}$

**解.** 因为

$$\begin{aligned} 0 &= dI = d(WW^{-1}) = dWW^{-1} + WdW^{-1} \\ WdW^{-1} &= -dWW^{-1} \\ dW^{-1} &= -W^{-1}dWW^{-1} \end{aligned}$$

所以

$$\begin{aligned} d\text{Tr}(W^{-1}) &= \text{Tr}(dW^{-1}) \\ &= \text{Tr}(-W^{-1}dWW^{-1}) \\ &= \text{Tr}(-(W^{-1})^2 dW) \end{aligned}$$

即

$$\frac{\partial \text{Tr}(W^{-1})}{\partial W} = -(W^{-T})^2$$

**习题 6.**  $(\exp(z))_i = \exp(z_i)$ ,  $(\log(z))_i = \log(z_i)$   $f(z) = \frac{\exp(z)}{\mathbf{1}^T \exp(z)}$  称为 *softmax* 函数, , 如果  $q = f(z)$ ,  $J = -p^T \log(q)$ , 其中  $p, q, z \in \mathbb{R}^n$ , 并且  $\mathbf{1}^T p = 1$ ,

- 证:  $\frac{\partial J}{\partial z} = q - p$
- 若  $z = Wx$ , 其中  $W \in \mathbb{R}^{n \times m}$ ,  $x \in \mathbb{R}^m$ ,  $\frac{\partial J}{\partial W} = (q - p)x^T$  是否成立。

**解.** •

$$\begin{aligned} J &= -p^T \log\left(\frac{\exp(z)}{\mathbf{1}^T \exp(z)}\right) \\ &= -p^T z + p^T \log(\mathbf{1}^T \exp(z)) \mathbf{1} \\ &= -p^T z + p^T \mathbf{1} \log(\mathbf{1}^T \exp(z)) \\ &= -p^T z + \log(\mathbf{1}^T \exp(z)) \end{aligned}$$

$$\begin{aligned}\frac{\partial J}{\partial \mathbf{z}} &= -\mathbf{p} + \frac{\partial \log(\mathbf{1}^T \exp(\mathbf{z}))}{\partial \mathbf{z}} \\ &= -\mathbf{p} + \frac{\partial \mathbf{1}^T \exp(\mathbf{z})}{\partial \mathbf{z}} \frac{1}{\mathbf{1}^T \exp(\mathbf{z})} \\ &= -\mathbf{p} + \frac{\exp(\mathbf{z})}{\mathbf{1}^T \exp(\mathbf{z})} \\ &= -\mathbf{p} + \mathbf{q}\end{aligned}$$

•

$$dJ = d \operatorname{Tr}(J) = \operatorname{Tr}(dJ) = \operatorname{Tr}[(\mathbf{-p} + \mathbf{q})^T d\mathbf{W}\mathbf{x}] = \operatorname{Tr}[\mathbf{x}(\mathbf{-p} + \mathbf{q})^T d\mathbf{W}]$$

$$\frac{\partial J}{\partial \mathbf{W}} = (\mathbf{-p} + \mathbf{q})\mathbf{x}^T$$