

# 数据科学与工程数学基础

## 作业提交规范及第 7 次作业

教师：黄定江

助教：刘文辉、徐艺玮

2024 年 1 月 8 日

### 作业提交规范

1. 作业提交形式：建议使用 Word 或  $\text{\LaTeX}$  编写所得到的电子文档。若使用 Word 编写，将其另存为 PDF 形式，然后提交 PDF 文档。若使用  $\text{\LaTeX}$  编写，将其编译成 PDF 形式，然后提交 Tex 和 PDF 两个文档。若使用手写拍照的方式，请务必规整好各题解答的图片，并整合在一个 PDF 文档中，只发图片格式的作业概不批改！
2. 作业命名规范：提交的电子文档必须命名为：“学号\_姓名”。命名示例：52200000000\_刘某某。
3. 作业提交途径：点击打开每次作业的传送门地址：[第 7 次作业提交传送门](#)，无需注册和登录，按要求输入个人学号和姓名，然后上传作业文档即可。注意：传送门将会在截至时间点到达后自动关闭。
4. 作业更改说明：如果需要修改已经提交的作业，只要在截至日期前，再次上传更改后的作业（切记保持同名），即可覆盖已有作业。
5. 作业评分说明：正常提交作业的按照实际评分记录；逾期补交作业的根据逾期情况在实际评分基础上酌情扣分；未交作业的当次作业记为 0 分；若发现存在抄袭的作业时，相似的两份作业均会被记为 0 分。

### 第 7 次作业



提交截至时间：2024/01/08 下周一 12:00（中午）

## 理论部分

**习题 1.** 写出下述非线性规划的 *KKT* 条件并求解

$$(1) \quad \text{maximize} \quad f(x) = (x-3)^2$$

$$\text{subject to} \quad 1 \leq x \leq 5$$

$$(2) \quad \text{minimize} \quad f(x) = (x-3)^2$$

$$\text{subject to} \quad 1 \leq x \leq 5$$

**解.** (1) 原问题等价于

$$\begin{cases} \text{minimize} & -f(x) = (x-3)^2 \\ g_1(x) = -x+1 \leq 5 \\ g_2(x) = x-5 \leq 0 \end{cases}$$

求目标函数和约束函数的梯度得,

$$\nabla_x f(x) = -2(x-3), \nabla_x g_1(x) = -1, \nabla_x g_2(x) = 1$$

将约束引入广义 *Lagrange* 乘子  $v_1, v_2$ , 在 *KKT* 条件上有

$$\begin{cases} -2(x^*-3) - v_1^* + v_2^* = 0 \\ v_1^*(-x^*+1) = 0 \\ v_2^*(x^*-5) = 0 \\ v_1^* \geq 0, v_2^* \geq 0 \end{cases}$$

若  $v_1^* \neq 0, v_2^* \neq 0$ , 无解.

若  $v_1^* = 0, v_2^* \neq 0$ , 得  $x^* = 5, v_2^* = 4, -f(x^*) = -4$ .

若  $v_1^* \neq 0, v_2^* = 0$ , 得  $x^* = 1, v_1^* = 4, -f(x^*) = -4$ .

若  $v_1^* = 0, v_2^* = 0$ , 得  $x^* = 3, f(x^*) = 0$ .

因此最优点  $x^* = 1$  或  $x^* = 5, \text{maximize} f(x) = 4$ .

(2) 原问题等价于

$$\begin{cases} \text{minimize} & f(x) = (x-3)^2 \\ g_1(x) = -x+1 \leq 5 \\ g_2(x) = x-5 \leq 0 \end{cases}$$

求目标函数和约束函数的梯度得,

$$\nabla_x f(x) = -2(x-3), \nabla_x g_1(x) = -1, \nabla_x g_2(x) = 1$$

将约束引入广义 *Lagrange* 乘子  $v_1, v_2$ , 在 *KKT* 条件上有

$$\begin{cases} 2(x^*-3) - v_1^* + v_2^* = 0 \\ v_1^*(-x^*+1) = 0 \\ v_2^*(x^*-5) = 0 \\ v_1^* \geq 0, v_2^* \geq 0 \end{cases}$$

若  $v_1^* \neq 0, v_2^* \neq 0$ , 无解.

若  $v_1^* = 0, v_2^* \neq 0$ , 得  $x^* = 5, v_2^* = -4 < 0$ , 不是  $KKT$  点.

若  $v_1^* \neq 0, v_2^* = 0$ , 得  $x^* = 1, v_1^* = -4 < 0$ , 不是  $KKT$  点.

若  $v_1^* = 0, v_2^* = 0$ , 得  $x^* = 3, f(x^*) = 0$ .

因此最优解  $x^* = 3, \text{minimize } f(x) = 0$ .

**习题 2.** 考虑等式约束的最小二乘问题

$$\begin{aligned} & \text{minimize} \quad \|\mathbf{Ax} - \mathbf{b}\|_2^2 \\ & \text{subject to} \quad \mathbf{Gx} = \mathbf{h} \end{aligned}$$

其中  $\mathbf{A} \in \mathbb{R}^{m \times n}, \text{rank}(\mathbf{A}) = n, \mathbf{G} \in \mathbb{R}^{p \times n}, \text{rank}(\mathbf{G}) = p$ . 给出  $KKT$  条件, 推导原问题最优解  $x^*$  以及对偶问题最优解  $v^*$  的表达式.

**解.** 求得 *Lagrangian* 函数为

$$\begin{aligned} L(x, v) &= \|Ax - b\|_2^2 + v^T(Gx - h) \\ &= x^T A^T A x + (G^T v - 2A^T b)^T x - v^T h \end{aligned}$$

可通过如下最优性条件得到函数最小值. 令梯度为 0 得,

$$\nabla_x L(x, v) = 2A^T A x + G^T v - 2A^T b = 0$$

因此当  $x = \frac{1}{2}(A^T A)^{-1}(G^T v - 2A^T b)$  时, *Lagrangian* 函数取得最小值.

对偶函数为  $g(x) = -\frac{1}{4}(G^T v - 2A^T b)^T (A^T A)^{-1}(G^T v - 2A^T b) - v^T h$ .

最优性条件为

$$\begin{cases} 2A^T(Ax^* - b) + G^T v^* = 0 \\ Gx^* = h \end{cases}$$

解方程得,

$$\begin{cases} v^* = 2(G(A^T A)^{-1}G^T)^{-1}(G(A^T A)^{-1}A^T b - h) \\ x^* = (A^T A)^{-1}(A^T b - G^T(G(A^T A)^{-1}G^T)^{-1}(G(A^T A)^{-1}A^T b - h)) \end{cases}$$

**习题 3.** 用 *Lagrange* 乘子法证明: 矩阵  $\mathbf{A} \in \mathbb{R}^{m \times n}$  的 2 范数

$$\|\mathbf{A}\|_2 = \max_{\|\mathbf{x}\|_2=1, \mathbf{x} \in \mathbb{R}^n} \|\mathbf{Ax}\|_2$$

的平方是  $\mathbf{A}^T \mathbf{A}$  的最大特征值。

**解.** 优化问题为

$$\begin{aligned} & \text{maximize} \quad f(\mathbf{x}) = \mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x} \\ & \text{subject to} \quad \mathbf{x}^T \mathbf{x} = 1 \end{aligned}$$

Lagrange 函数为:

$$L(\mathbf{x}) = \mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x} - \lambda(\mathbf{x}^T \mathbf{x} - 1)$$

$$\frac{\partial L}{\partial \mathbf{x}} = 2\mathbf{A}^T \mathbf{A} \mathbf{x} - 2\lambda \mathbf{x}$$

令  $\frac{\partial L}{\partial \mathbf{x}} = 0$ , 有:

$$\mathbf{A}^T \mathbf{A} \mathbf{x} = \lambda$$

这表示在  $f(\mathbf{x})$  的极大值点,  $\mathbf{x}$  是  $\mathbf{A}^T \mathbf{A}$  的特征向量,  $\lambda$  是对应的特征值。此时,

$$f(\mathbf{x}) = \mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x} = \mathbf{x}^T \lambda \mathbf{x} = \lambda \mathbf{x}^T \mathbf{x} = \lambda$$

因此说明, 为使  $f(\mathbf{x})$  最大,  $f(\mathbf{x}) = \lambda_{\max}(\mathbf{A}^T \mathbf{A})$ , 其中  $\lambda_{\max}$  表示最大特征值。即

$$\|\mathbf{A}\|_2^2 = \lambda_{\max}(\mathbf{A}^T \mathbf{A})$$

**习题 4.** 用 Lagrange 乘子法求欠定方程  $\mathbf{A}\mathbf{x} = \mathbf{b}$  的最小二范数解, 其中  $\mathbf{A} \in \mathbb{R}^{m \times n}, m \leq n, \text{rank}(\mathbf{A}) = m$

**解.** 优化问题为

$$\text{minimize } f(\mathbf{x}) = \frac{1}{2} \|\mathbf{x}\|_2^2$$

$$\text{subject to } \mathbf{A}\mathbf{x} = \mathbf{b}$$

Lagrange 函数为:

$$L(\mathbf{x}, \boldsymbol{\lambda}) = \frac{1}{2} \mathbf{x}^T \mathbf{x} - \boldsymbol{\lambda}^T (\mathbf{A}\mathbf{x} - \mathbf{b})$$

$$\frac{\partial L}{\partial \mathbf{x}} = \mathbf{x} - \mathbf{A}^T \boldsymbol{\lambda}$$

令  $\frac{\partial L}{\partial \mathbf{x}} = 0$ , 有:

$$\mathbf{x} = \mathbf{A}^T \boldsymbol{\lambda}$$

$$g(\boldsymbol{\lambda}) = -\frac{1}{2} \boldsymbol{\lambda}^T \mathbf{A} \mathbf{A}^T \boldsymbol{\lambda} + \boldsymbol{\lambda}^T \mathbf{b}$$

令  $\frac{\partial g}{\partial \boldsymbol{\lambda}} = 0$ :

$$-\mathbf{A} \mathbf{A}^T \boldsymbol{\lambda} + \mathbf{b} = 0$$

由  $\mathbf{A} \in \mathbb{R}^{m \times n}, \text{rank}(\mathbf{A}) = m$  得  $\mathbf{A} \mathbf{A}^T$  可逆, 因此

$$\boldsymbol{\lambda} = (\mathbf{A} \mathbf{A}^T)^{-1} \mathbf{b}$$

因此,  $\mathbf{x}$  满足  $\mathbf{A}\mathbf{x} = \mathbf{b}$  的最小二范数解:

$$\mathbf{x} = \mathbf{A}^T (\mathbf{A} \mathbf{A}^T)^{-1} \mathbf{b}$$

**习题 5.** 用最速下降法和精确线搜索计算  $\min f(\mathbf{x}) = x_1^2 + x_2^2 + x_3^2$ , 初始点  $\mathbf{x}^{(0)} = (2, 2, 1)^T$ . 当  $(f(\mathbf{x}^{(n+1)}) - f(\mathbf{x}^{(n)})) < 0.001$  时迭代终止.

**解.** 由题意得,  $f(x) = x^T x, \nabla_x f(x) = 2x$ , 设最速下降法的步长为  $\lambda$ , 那么

$$\begin{aligned} f(x - \lambda \nabla_x f(x)) &= (x - \lambda \nabla_x f(x))^T (x - \lambda \nabla_x f(x)) \\ &= x^T x - 2\lambda \nabla_x f(x)^T x + \lambda^2 \nabla_x f(x)^T \nabla_x f(x) \end{aligned}$$

在  $x - \lambda \nabla_x f(x)$  方向上, 使  $f(x)$  最小的  $\lambda$  满足

$$\frac{\partial f(x - \lambda \nabla_x f(x))}{\partial \lambda} = -2\nabla_x f(x)^T x + 2\lambda \nabla_x f(x)^T \nabla_x f(x)$$

得

$$\lambda = \frac{\nabla_x f(x)^T x}{\nabla_x f(x)^T \nabla_x f(x)} = \frac{1}{2}$$

所以,

$$x^{(1)} = x^{(0)} - \frac{1}{2} \nabla_x f(x^{(0)}) = (0, 0, 0)^T$$

$$f(x^{(1)}) = 0$$

$$x^{(2)} = x^{(1)} - \frac{1}{2} \nabla_x f(x^{(1)}) = (0, 0, 0)^T$$

$$f(x^{(2)}) = 0$$

同理可得,  $f(x^{(n)}) = 0 (n > 0)$ , 因此当  $|f(x^{(n+1)}) - f(x^{(n)})| = 0 < 0.001$  时, 迭代终止.

**习题 6.** 使用梯度下降法和固定步长  $\lambda = 0.01$  计算  $\min f(x) = (x_1 - 1)^2 + 16(x_2 - 2)^2$ , 初始点  $x^{(0)} = (2, 3)^T$ , 迭代两步后终止.

**解.** 具体迭代结果:

$k$	$x^{(k)^T}$	$g_k^T$	$f_k$	$\ g_k\ _\infty$
0	(2, 3)	(2, 32)	17	32
1	(1.98, 2.68)	[1.96, 21.76]	8.3588	21.76
2	(1.96, 2.46)	[1.9208, 14.7968]	4.3434	14.7968

**习题 7.** 考虑问题

$$\min f(x) = 3x_1^2 + 3x_2^2 - x_1^2 x_2.$$

从初始点  $x^{(0)} = (1.5, 1.5)^T$  出发, 用 *Newton* 方法求迭代两步后该问题的解 (可用编写程序辅助计算).

**解.**  $f(x)$  的一、二阶导数分别为

$$g(x) = (6x_1 - 2x_1x_2, 6x_2 - x_1^2)^T, \quad G(x) = \begin{bmatrix} 6 - 2x_2 & -2x_1 \\ -2x_1 & 6 \end{bmatrix}$$

$f(x)$  有三个稳定点: 极小点  $x_{(1)} = (0, 0)^T$ , 鞍点  $x_{(2)} = (3\sqrt{2}, 3)^T$  和  $x_{(3)} = (-3\sqrt{2}, 3)^T$ . 在这三个点的 *Hesse* 矩阵分别为

$$G(x_{(1)}) = \begin{bmatrix} 6 & 0 \\ 0 & 6 \end{bmatrix}, \quad G(x_{(2)}) = \begin{bmatrix} 0 & -6\sqrt{2} \\ -6\sqrt{2} & 6 \end{bmatrix}$$

$$G(x_{(3)}) = \begin{bmatrix} 0 & 6\sqrt{2} \\ 6\sqrt{2} & 6 \end{bmatrix}.$$

下面我们从  $x^{(0)} = (1.5, 1.5)^T$ , 这时 *Newton* 方法在每一迭代步的信息见下表

$k$	$x^{(k)^T}$	$f_k$	$\ g_k\ _\infty$
0	(1.5000, 1.5000)	10.1250	8.1125
1	(-3.7500, -2.2500)	89.0156	48.0633
2	(0.6250, -3.1250)	31.6895	20.6151
3	(0.3190, 0.0014)	0.3052	1.9155
4	(-0.0020, -0.0172)	0.0009	0.1037
5	(-0.0000, -0.0000)	0.0000	0.0000
6	(-0.0000, -0.0000)	0.0000	0.0000